



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE CIÊNCIAS
DEPARTAMENTO DE COMPUTAÇÃO
CIÊNCIA DE DADOS
INTELIGÊNCIA ARTIFICIAL

KADSON RODRIGUES DE SOUSA
LARISSA MACIEL DA SILVA
SANDY ALMIR BONFIM
PATRÍCIA FREIRE SONGO

RELATÓRIO TÉCNICO: SISTEMA INTELIGENTE DE TRIAGEM EM
PRONTO-SOCORRO

INTRODUÇÃO

Os serviços de pronto-socorro enfrentam constantemente o problema da superlotação, o que aumenta o tempo de espera dos pacientes e pode comprometer a qualidade do atendimento, especialmente para aqueles em estado mais grave. Nesse contexto, técnicas de Inteligência Artificial podem contribuir para tornar o processo de triagem mais eficiente e apoiar a tomada de decisão de forma objetiva.

Este trabalho propõe o desenvolvimento de um sistema inteligente para apoio à triagem hospitalar, integrando Redes Bayesianas e o algoritmo de busca heurística A*. A Rede Bayesiana é utilizada para estimar a probabilidade de gravidade dos pacientes a partir de informações clínicas, enquanto o algoritmo A* utiliza essa estimativa para definir uma ordem de atendimento que minimize o risco associado ao tempo de espera. Dessa forma, o sistema considera simultaneamente a gravidade estimada e o tempo de espera, buscando uma estratégia mais eficiente do que abordagens tradicionais, como FIFO e a seleção gulosa do paciente mais grave.

Para avaliar a solução proposta, foram realizados experimentos comparando as estratégias FIFO, Gulosa e A* em diferentes cenários de atendimento. Os resultados permitem analisar o impacto da integração entre a Rede Bayesiana e o algoritmo de busca na redução do risco acumulado dos pacientes, evidenciando o potencial da Inteligência Artificial como ferramenta de apoio à decisão em ambientes hospitalares.

DESENVOLVIMENTO

Modelagem da Rede Bayesiana

O primeiro módulo do sistema foi desenvolvido utilizando Redes Bayesianas, uma técnica de Inteligência Artificial capaz de representar relações probabilísticas entre diferentes variáveis e realizar inferências sob incerteza. A implementação foi realizada na linguagem Python com o auxílio da biblioteca pgmpy, responsável pela construção da topologia da rede, definição das Tabelas de Probabilidade Condicional (CPTs) e execução do algoritmo de inferência.

A estrutura da rede foi modelada considerando variáveis clínicas frequentemente utilizadas em protocolos de triagem hospitalar (como o Protocolo de Manchester). Foram selecionadas as variáveis: *Febre*, *Saturação de Oxigênio*, *Pressão Arterial*, *Frequência Cardíaca*, *Nível de Dor*, *Idade* e *Doença Crônica*, as quais influenciam diretamente a variável dependente central *Gravidade*.

Inicialmente, os dados provenientes da base de pacientes passaram por um processo de discretização. Variáveis contínuas (temperatura corporal, saturação de oxigênio, pressão arterial e frequência cardíaca) foram convertidas em categorias clínicas ordinais, reduzindo a dimensionalidade e a complexidade do espaço amostral da rede. A idade foi dividida em dois grupos (<60 anos e ≥ 60 anos), enquanto a presença de doença crônica foi representada de forma binária.

Após a discretização, foram calculadas as distribuições de probabilidade das variáveis de entrada utilizando suas frequências observadas na base de dados. Para a variável *Gravidade*, construiu-se uma CPT baseada em um sistema de pontuação clínica (escore). Cada condição recebeu um peso ponderado proporcional à sua relevância clínica, atribuindo maior impacto a fatores críticos, tais como saturação de oxigênio severamente baixa, hipotensão, taquicardia/bradicardia, idade avançada e comorbidades. A soma desses pesos determina o escore final utilizado para calcular as probabilidades marginais dos três níveis de gravidade do paciente: baixa, média e alta.

Com a estrutura da rede definida e as CPTs parametrizadas, o modelo foi validado. Em seguida, as inferências probabilísticas geraram, para cada perfil de paciente, a distribuição de probabilidade da variável *Gravidade*, que serve como dado de entrada para o módulo de busca.

Formulação do Problema de Busca

O segundo módulo do sistema consiste na implementação do algoritmo A*, responsável por determinar a ordem ótima de atendimento dos pacientes na fila de espera. O problema foi modelado no espaço de estados da seguinte forma:

- **Estado (n):** Representa o subconjunto de pacientes que ainda aguardam atendimento, associados aos seus respectivos tempos de espera atuais e às probabilidades de gravidade estimadas pela Rede Bayesiana.
- **Estado Inicial:** A fila completa de pacientes com tempo de espera zerado (ou correspondente ao momento da triagem).
- **Estado Objetivo:** O conjunto vazio de pacientes (todos os indivíduos atendidos).
- **Ações:** A escolha do próximo paciente a ser atendido a partir do estado atual. A cada ação, o paciente escolhido é removido da fila e o tempo de espera dos demais é incrementado pelo tempo gasto no atendimento decorrente.

O custo real de transição $g(n)$ para atingir um estado foi definido pelo risco acumulado dos pacientes que permanecem aguardando. O risco individual de um paciente i em um determinado instante é calculado pelo produto da probabilidade de gravidade alta, obtida via Rede Bayesiana, pelo seu tempo atual de espera, conforme a Equação:

$$Risco_i = P(Gravidade = Alta) * TempoDeEspera_i$$

Para orientar o algoritmo A^* , a função de avaliação é dada por $f(n) = g(n) + h(n)$. A função heurística $h(n)$ foi projetada como a soma dos riscos atuais de todos os pacientes que ainda restam na fila no estado n . Visto que o tempo de espera dos pacientes restantes apenas aumentará com os atendimentos subsequentes, o risco atual subestima o risco real futuro, garantindo que $h(n)$ seja uma heurística admissível e, consequentemente, assegurando a otimalidade do algoritmo A^* .

Para fins de benchmark, foram implementadas outras duas estratégias de ordenação: a política *First In, First Out* (FIFO), que atende por ordem estrita de chegada de forma agnóstica ao quadro clínico; e uma abordagem *Gulosa* (Greedy), que prioriza unicamente os pacientes com maior $P(Gravidade = Alta)$, ignorando o tempo de espera.

Integração entre os Módulos

A integração dos módulos operacionaliza o sistema de apoio à decisão. O fluxo inicia-se com o processamento dos sinais vitais do paciente na Rede Bayesiana. O valor

inferido para a probabilidade do estado *Gravidade Alta* é exportado diretamente para o algoritmo A*, funcionando como o peso clínico do paciente.

Como o risco é dinâmico e cresce linearmente com o tempo, o algoritmo A* avalia as permutações de atendimento no grafo de estados, ponderando o compromisso (*trade-off*) entre a urgência clínica e o tempo de abandono na fila.

Por fim, os experimentos foram divididos em dois cenários computacionais:

1. **Cenário Reduzido (6 pacientes):** Onde o algoritmo A* foi executado com sucesso, encontrando a sequência ótima de atendimento.
2. **Cenário Ampliado (25 pacientes):** Destinado à comparação exclusiva entre as heurísticas FIFO e Gulosa. A execução do algoritmo A* tornou-se inviável neste cenário devido ao fenômeno da explosão combinatória (crescimento fatorial do espaço de estados, $25!$), uma limitação típica de algoritmos de busca exaustiva exata quando aplicados a problemas de larga escala sem funções de poda agressivas.

RESULTADOS

Com o objetivo de avaliar o desempenho do sistema proposto, foram realizados experimentos envolvendo tanto o módulo de inferência probabilística quanto o algoritmo de busca. Inicialmente, foi verificado o correto funcionamento da Rede Bayesiana por meio da discretização das variáveis clínicas, validação da estrutura do modelo e realização de inferências para diferentes perfis de pacientes. Posteriormente, foram comparadas três estratégias de ordenação da fila de atendimento: FIFO, Gulosa e A*.

Validação da Rede Bayesiana

Inicialmente, os dados clínicos da base foram discretizados conforme as categorias definidas durante a modelagem. A Figura 1 apresenta uma amostra da base após esse processo, evidenciando a transformação das variáveis contínuas em estados discretos adequados para utilização na Rede Bayesiana.

Figura 1 – Amostra da base de dados após o processo de discretização.

Primeiras linhas da base:

	paciente	Febre	Saturação de O ₂	Pressão Arterial	Frequência Cardíaca	\
0	Paciente_01	35.5	96	110/81	83	
1	Paciente_02	36.8	96	116/79	69	
2	Paciente_03	35.6	98	114/72	83	
3	Paciente_04	36.7	96	119/76	64	
4	Paciente_05	36.2	98	110/73	66	


	Nível de Dor	Idade	Doença Crônica	tempo de espera
0	3	30	0	147
1	0	28	0	87
2	3	24	0	163
3	2	39	0	73
4	0	24	0	155

Colunas da base:
['paciente', 'Febre', 'Saturação de O₂', 'Pressão Arterial', 'Frequência Cardíaca', 'Nível de Dor', 'Idade', 'Doença Crônica', 'tempo de espera']

Fonte: figura autoral

Após a discretização, foi construída e validada a estrutura da Rede Bayesiana. A Figura 2 apresenta a topologia implementada, na qual todas as variáveis clínicas influenciam diretamente a variável Gravidade.

Figura 2 – Estrutura da Rede Bayesiana utilizada no sistema.



Fonte: figura autoral

A validação do modelo confirmou que todas as Tabelas de Probabilidade Condicional (CPTs) foram corretamente definidas, permitindo a realização das inferências probabilísticas.

Foram realizados testes de inferência para diferentes perfis clínicos. Inicialmente, foi calculada a distribuição de probabilidades da variável **Gravidade** sem qualquer evidência clínica, obtendo-se aproximadamente **57,18%** de probabilidade de gravidade baixa, **26,32%** de gravidade média e **16,50%** de gravidade alta. Em seguida, simulou-se um paciente apresentando febre alta, saturação reduzida, pressão arterial baixa, dor intensa, idade superior a 60 anos e doença crônica. Para esse cenário, a Rede Bayesiana estimou uma probabilidade de aproximadamente **85%** para gravidade alta, indicando corretamente um quadro clínico crítico. Por fim, foi analisado um paciente jovem, sem doença crônica e com sinais vitais dentro da normalidade. Nesse caso, o modelo estimou aproximadamente **85%** de probabilidade de gravidade baixa e apenas **2%** de probabilidade de gravidade alta, demonstrando comportamento coerente com as evidências fornecidas.

Além dos exemplos simulados, também foi realizada a inferência para pacientes reais presentes na base de dados, confirmando o correto funcionamento do modelo probabilístico antes da integração com o algoritmo de busca.

Comparação das Estratégias de Atendimento

Após a obtenção das probabilidades de gravidade para cada paciente, essas informações passaram a ser utilizadas pelo algoritmo A* para calcular o risco associado ao tempo de espera. Foram considerados dois cenários experimentais:

1. **Cenário Reduzido:** O primeiro cenário foi composto por seis pacientes, permitindo a execução completa do algoritmo A*. Os resultados obtidos encontram-se resumidos na Tabela 1.
2. **Cenário Ampliado:** O segundo experimento foi realizado utilizando vinte e cinco pacientes. Devido ao crescimento fatorial do espaço de estados (aproximadamente $25!$ combinações possíveis), a execução completa do algoritmo A* tornou-se computacionalmente inviável. Assim, foram executadas apenas as estratégias FIFO e Gulosa.

Tabela 1 – Comparação das estratégias no cenário com seis pacientes.

Estratégia	Risco Acumulado Total
FIFO	35,94
Gulosa	43,54
A*	35,94

Fonte: figura autoral

Tabela 2 – Comparação das estratégias no cenário com vinte e cinco pacientes.

Estratégia	Risco Acumulado Total
FIFO	11605,99
Gulosa	1688,26

Fonte: figura autoral

Os resultados apresentados nas **Tabelas 1 e 2** permitem comparar o desempenho das estratégias de atendimento nos dois cenários avaliados.

No cenário reduzido, o algoritmo A* encontrou uma solução ótima, apresentando o menor risco acumulado entre as estratégias comparadas. Embora tenha obtido o mesmo risco da estratégia FIFO, as ordens de atendimento foram diferentes, mostrando que sequências distintas podem produzir o mesmo custo acumulado. Já a estratégia Gulosa apresentou o maior risco, indicando que considerar apenas a gravidade clínica não é suficiente quando o tempo de espera também influencia o custo total. No cenário ampliado, a estratégia Gulosa apresentou um risco acumulado significativamente menor que o FIFO, evidenciando que utilizar a gravidade clínica como critério de priorização produz melhores resultados do que atender apenas por ordem de chegada. O algoritmo A* não foi executado nesse cenário devido ao crescimento fatorial do espaço de estados, tornando sua aplicação computacionalmente inviável para um grande número de pacientes.

De modo geral, os resultados demonstram que a integração entre a Rede Bayesiana e o algoritmo A* permite combinar gravidade clínica e tempo de espera na definição da ordem de atendimento, produzindo decisões mais fundamentadas e eficientes.

CONCLUSÃO

Os resultados obtidos demonstraram que a Rede Bayesiana foi capaz de produzir estimativas coerentes da gravidade dos pacientes a partir de seus sinais vitais e informações clínicas. Além disso, a integração entre a Rede Bayesiana e o algoritmo A* permitiu incorporar simultaneamente a gravidade estimada e o tempo de espera na tomada de decisão, tornando o processo de priorização mais fundamentado do que estratégias baseadas apenas na ordem de chegada ou apenas na gravidade clínica.

Nos experimentos realizados, verificou-se que o algoritmo A* encontrou uma solução ótima no cenário reduzido, enquanto a estratégia Gulosa apresentou desempenho superior ao FIFO no cenário ampliado. Esses resultados evidenciam a importância da utilização de informações probabilísticas para apoiar a definição da ordem de atendimento em ambientes de emergência. Como principal limitação, destaca-se que a execução do algoritmo A* torna-se inviável para filas muito grandes devido ao crescimento fatorial do espaço de estados. Além disso, as probabilidades condicionais da variável **Gravidade** foram definidas com base em critérios clínicos plausíveis, não sendo aprendidas automaticamente a partir de uma base de dados rotulada.

De modo geral, os objetivos propostos foram alcançados, demonstrando que a integração entre Redes Bayesianas e algoritmos de busca heurística constitui uma abordagem viável para apoiar a tomada de decisão em processos de triagem hospitalar, contribuindo para uma alocação mais eficiente das prioridades de atendimento.

REFERÊNCIAS

RUSSELL, Stuart; NORVIG, Peter. *Inteligência artificial*. Tradução de Regina Célia Simille. Rio de Janeiro: Elsevier, 2013. Disponível em: [Kufunda](#). Acesso em: 20 jun. 2026.